临床医学公开数据库课程报告

基于 PIC 衍生教学数据的儿童重症患者院内死亡风险预测

肖璇

2611210700@stu.pku.edu.cn

摘要

目的：利用 PIC 衍生教学数据评价儿童重症患者院内死亡预测，并以同参数消融衡量缺失指示的增量贡献。方法：纳入 13,258 条记录，死亡 780 条（5.88%）。按标签分层划分训练集和测试集，使用训练集五折交叉验证选择模型与阈值。在留出测试集上比较排序、概率误差和校准，并进行配对分层 bootstrap。结果：主模型为带缺失指示的随机森林。其测试 AUROC 为 0.724 [0.681, 0.768]，AP 为 0.228 [0.171, 0.297]，Brier 为 0.051 [0.049, 0.053]。相对普通 LR，AUROC 差值为 +0.0347 [+0.0060, +0.0643]，Brier 差值为 -0.0013 [-0.0024, -0.0002]。相对同参数无指示随机森林，AUROC 差值为 +0.0114 [-0.0015, +0.0232]，AP 差值为 +0.0078 [-0.0066, +0.0175]。结论：逻辑回归加入缺失指示未显示有实质增益。随机森林相对普通 LR 的排序改善大部分在无指示模型中已出现，提示主要来自非线性建模。缺失指示的额外贡献较小且不确定。Brier 绝对值仅略有改善。**关键词：**PIC，院内死亡，随机森林，消融实验，概率校准

1 数据来源、队列与数据读取

PIC 是中国单中心儿科重症数据库 [1]。本分析读取课程提供的 `data.xlsx`。输入为月龄及五项匿名实验室特征，结局为 `HOSPITAL_EXPIRE_FLAG`。统计单位为记录。Hong 等 [2] 在入院后前 24 小时汇总时间变化特征，排除了这段时间内死亡的 191 例。其表 1 报告开发集 10,606 例和测试集 2,652 例，共 13,258 例。两组分别死亡 630 例和 150 例，合计 780 例。教学文件共 13,258 条记录、死亡 780 条，与论文总数完全一致，提示可能来自同一排除后的队列。文件没有时间字段或患者 ID，无法核对个体、采集窗口和排除过程。本报告训练和测试集死亡数分别为 624 和 156，与论文划分的 630 和 150 不同。

表 1: 数据读取与分析人群

分析阶段	记录数	死亡数
原始及清理后	13,258	780
训练集	10,606	624
留出测试集	2,652	156
关联回归完整记录	8,539	587

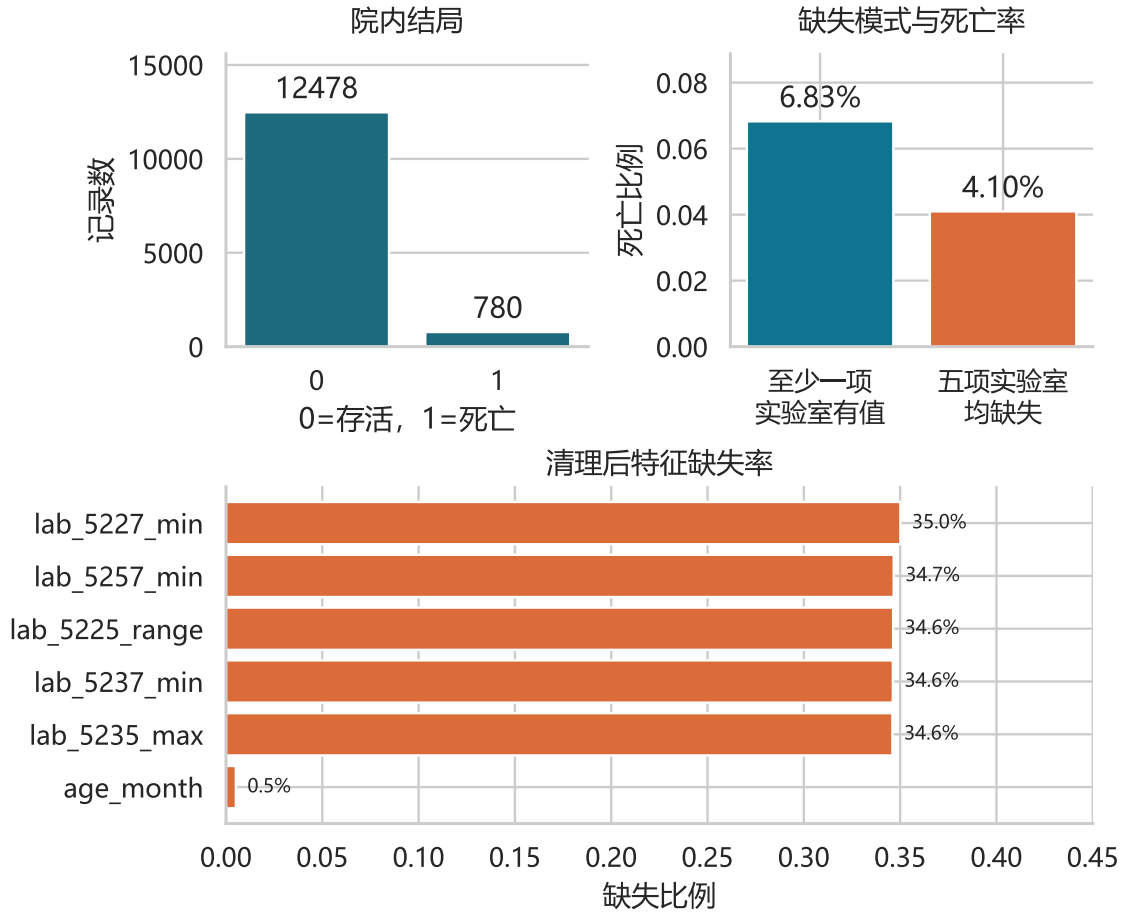


图 1: 结局、缺失模式及各特征缺失率。

2 预处理、缺失模式与描述性统计

将 68 条负月龄设为缺失，零月龄保留。原始月龄超过 216 个月的 2 条记录保留并做敏感性评价。保留 4,306 条重复特征及结局记录，因为没有患者 ID 可以确认重复个体。五项实验室均缺失的记录有 4,587 条。训练折内拟合中位数插补，逻辑回归另做标准化。含指示模型在插补前记录缺失状态。所有预测预处理均在 Pipeline 内进行。描述性比较使用非缺失观测及双侧 Mann–Whitney U 检验，按 BH 校正。SMD 为死亡组减存活组的标准化均值差。

表 2: 按结局描述非缺失观测

变量	存活中位数 [IQR]	死亡中位数 [IQR]	SMD	BH q
age_month	9 [1, 42]	5 [0, 31]	-0.060	0.00016
lab_5237_min	7.37 [7.31, 7.42]	7.3 [7.16, 7.37]	-0.690	8.4e-53
lab_5227_min	1.8 [1.2, 2.7]	2 [1.2, 3.2]	0.241	0.00079
lab_5225_range	1.2 [0, 5.7]	5.2 [0.475, 11.1]	0.541	1.9e-39
lab_5235_max	39.3 [34, 46.1]	46.4 [37.1, 60.4]	0.528	7.7e-36
lab_5257_min	107 [55, 132]	15.2 [9.4, 103]	-0.677	8.4e-53

表 3: 按结局的观测数与缺失数

变量	存活观测	死亡观测	存活缺失	死亡缺失
age_month	12412	778	66	2
lab_5237_min	8076	592	4402	188
lab_5227_min	8026	590	4452	190
lab_5225_range	8074	592	4404	188
lab_5235_max	8079	592	4399	188
lab_5257_min	8072	590	4406	190

缺失比例在结局组间不同。缺失状态可能包含记录过程的信息，现有字段不足以识别缺失机制。

3 探索性统计关联与共线性

单因素回归使用各变量非缺失记录，多因素回归使用六特征完整记录。各自按对应分析样本的 IQR 缩放，OR 表示增加一个 IQR 的关联，区间由 HC0 稳健标准误计算。两个模型的分析人群及 IQR 可能不同，OR 变化不能只归因于协变量调整。

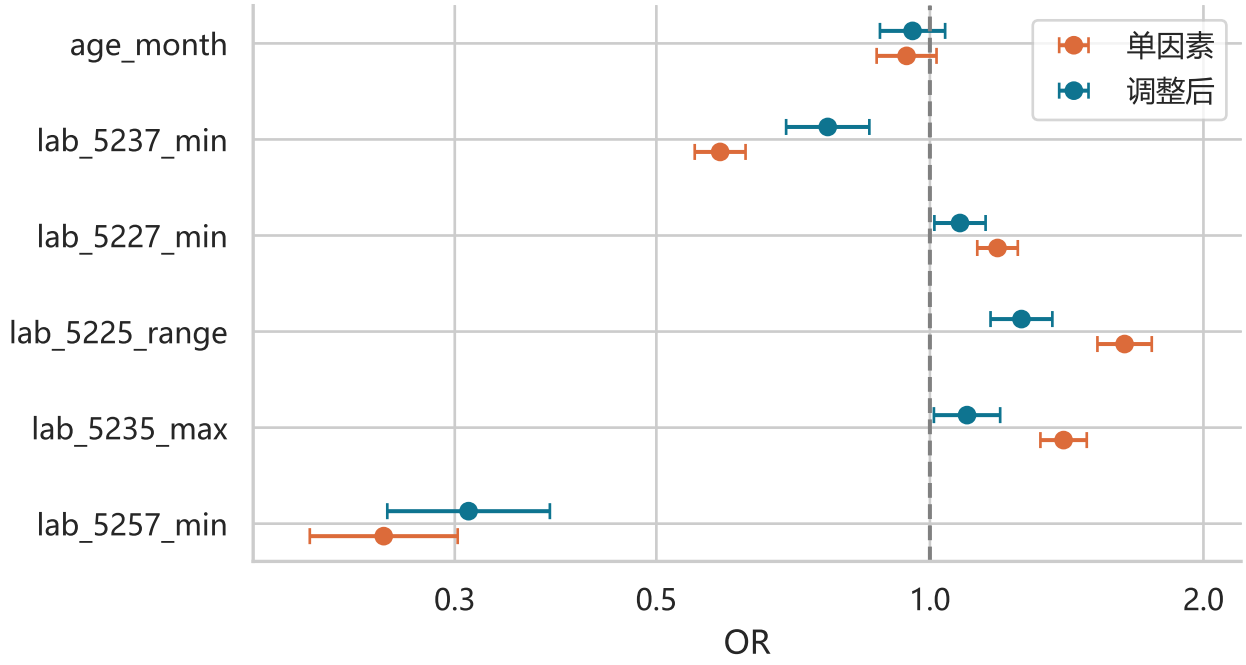


图 2: 单因素与调整后 OR 及 95% CI。横轴采用对数尺度。

表 4: 单因素与多因素 OR 对照（95% CI）

变量	IQR：单 / 多	单因素 OR	调整后 OR	VIF
age_month	41 / 36	0.943 [0.874, 1.017]	0.957 [0.881, 1.039]	1.04
lab_5237_min	0.109 / 0.108	0.588 [0.551, 0.627]	0.772 [0.695, 0.858]	2.77
lab_5227_min	1.5 / 1.5	1.187 [1.128, 1.250]	1.079 [1.011, 1.152]	1.21
lab_5225_range	6 / 6	1.638 [1.529, 1.755]	1.261 [1.166, 1.364]	1.32
lab_5235_max	12.7 / 12.8	1.403 [1.323, 1.488]	1.099 [1.010, 1.195]	2.25
lab_5257_min	113 / 113	0.251 [0.208, 0.302]	0.311 [0.253, 0.382]	1.08

表 5: 月龄组死亡率及分组敏感性回归

月龄	记录数	死亡	死亡率	调整 OR [95% CI]
不超过 1	3844	270	7.02%	1.522 [1.143, 2.026]
(1, 12]	3502	217	6.20%	1.432 [1.053, 1.947]
(12, 36]	2257	109	4.83%	1.413 [1.009, 1.979]
(36, 120]	2625	119	4.53%	参照
>120	962	63	6.55%	1.459 [0.959, 2.220]

月龄的 Mann–Whitney 检验 BH $q = 0.000164$，检验的是两结局组的秩分布差异。单因素和调整后的线性 OR 区间均含 1。表 5显示死亡率随月龄先降后升，单一线性项不能表达这种形状。敏感性模型保留其他五项变量，在完整记录上以 $(36, 120]$ 月为参照，用月龄组替代线性月龄。分组 OR 仍是探索性关联。`lab_5257_min` 呈双峰（图 7）。非缺失值的第 5、25 和 50 百分位为 7.7、17.6 和 105。低于 30 的记录占 25.72%，死亡率为 14.00%，其余记录为 4.32%。按 IQR 缩放的线性 OR 难以描述两个值簇之间的变化。30 是基于分布的探索性界点，无临床阈值含义。变量的临床定义和单位未知。

表 6: 双峰变量按探索性界点分组

范围	记录数	死亡	死亡率
至少 30	6434	278	4.32%
低于 30	2228	312	14.00%

4 预测模型建立与训练集选择

随机种子固定为 42，按标签分层作 80/20 划分。原候选模型使用相同的训练集五折分层 CV，按平均 AP 选参数及主模型。普通 LR 和平衡权重 LR 的 $C = 1$，缺失指示 LR 的候选 C 值为 0.1、1 和 10。主随机森林搜索深度 5 或不限、叶节点最少 5 或 20 条记录，树数固定为 200。以训练 CV 选出的带指示随机森林为主模型。消融模型固定其参数（200 棵树、叶节点最少 5 条、深度不限），仅用中位数插补。消融使用同样的 CV 折用于比较，不参与重新选择主模型。选定参数后，按训练集五折折外（OOF）预测，在灵敏度至少 0.80 的候选阈值中最大化特异度。阈值在测试前冻结。折间 SD 描述交叉验证的波动。

表 7: 训练集五折交叉验证

模型	AP 均值	AP 折间 SD	AUROC	Brier
无信息基线	0.059	0.000	0.500	0.055
普通 LR	0.191	0.030	0.717	0.052
平衡权重 LR	0.191	0.027	0.717	0.201
LR + 缺失指示	0.191	0.029	0.716	0.052
RF + 缺失指示	0.222	0.036	0.728	0.051
RF 无指示	0.219	0.037	0.726	0.051

5 测试集性能与不确定性

在 2,652 条测试记录（死亡 156 条）上评价连续分数。AP 为按召回增量加权的平均精确率，Brier 为概率平方误差。固定模型与阈值后，按结局分层重采样 1,000 次，以百分位数计算 95% CI。全部模型共用重采样索引。差值点估计来自原测试集，区间来自逐次配对差值。

表 8: 留出测试集性能 [95% CI]

模型	AUROC	AP	Brier
无信息基线	0.500 (—)	0.059 (—)	0.055 (—)
普通 LR	0.690 [0.642, 0.740]	0.182 [0.139, 0.246]	0.052 [0.050, 0.054]
平衡权重 LR	0.688 [0.639, 0.738]	0.181 [0.140, 0.247]	0.199 [0.194, 0.205]
LR + 缺失指示	0.691 [0.642, 0.741]	0.183 [0.140, 0.247]	0.052 [0.050, 0.054]
RF + 缺失指示	0.724 [0.681, 0.768]	0.228 [0.171, 0.297]	0.051 [0.049, 0.053]
RF 无指示	0.713 [0.669, 0.757]	0.220 [0.166, 0.291]	0.051 [0.049, 0.053]

表 9: 主模型减对照模型的测试性能差值 [95% CI]

对照模型	AUROC	AP	Brier
RF 无指示	+0.0114 [-0.0015, +0.0232]	+0.0078 [-0.0066, +0.0175]	-0.0002 [-0.0005, +0.0002]
普通 LR	+0.0347 [+0.0060, +0.0643]	+0.0452 [+0.0106, +0.0790]	-0.0013 [-0.0024, -0.0002]

表 9中，同参数消融的三个区间均跨 0，缺失指示的附加贡献较小且不确定。普通 LR 与指示 LR 的测试 AP 分别为 0.182 与 0.183，未见实质增益。主模型相对普通 LR 的排序能力有所提高，Brier 绝对值仅略有改善。

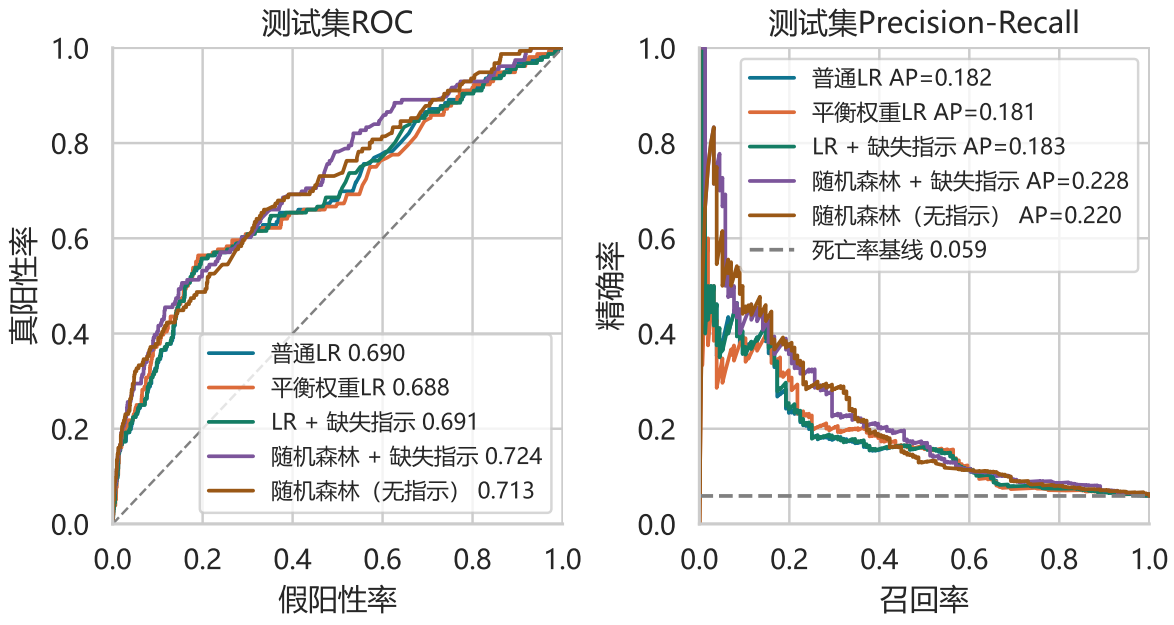


图 3: 留出测试集 ROC 与 PR 曲线。PR 虚线表示测试集死亡比例。

6 概率校准与分类阈值

测试集按预测概率分位数划分为最多八箱。另用二项 logistic 回归同时估计截距和斜率，自变量为预测概率的 log-odds，概率先裁到 [0.000001, 0.999999]。区间为模型标准误的 Wald 95% CI。理想截距为 0，斜率为 1。该回归只诊断校准，不修改预测。

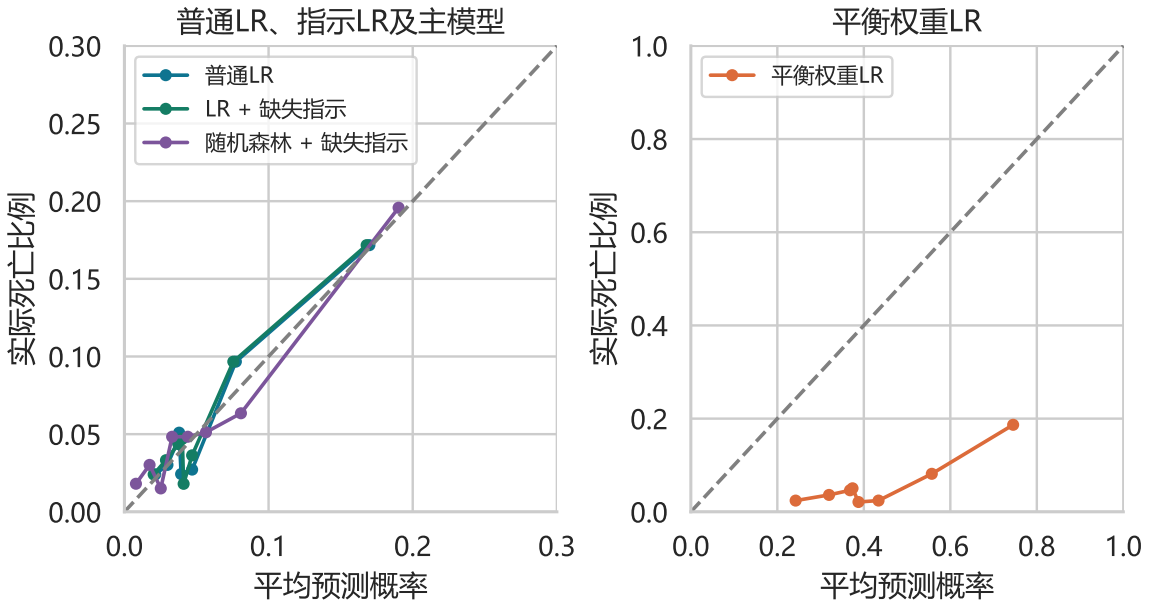


图 4: 左：普通 LR、指示 LR 和主模型，坐标范围 0–0.3。右：平衡权重 LR，坐标范围 0–1。虚线表示理想校准。

表 10: 测试集校准回归 [95% CI]

模型	校准截距	校准斜率
普通 LR	-0.004 [-0.519, 0.512]	0.988 [0.799, 1.177]
平衡权重 LR	-2.736 [-2.906, -2.566]	0.839 [0.676, 1.002]
LR + 缺失指示	0.005 [-0.515, 0.525]	0.990 [0.800, 1.181]
RF + 缺失指示	-0.132 [-0.581, 0.317]	0.931 [0.763, 1.099]

表 11: 训练 OOF 冻结阈值在测试集的表现

模型	阈值	灵敏度	特异度	PPV	F1	FP / FN
普通 LR	0.0382	0.699	0.494	0.080	0.143	1262 / 47
平衡权重 LR	0.3765	0.673	0.498	0.077	0.139	1253 / 51
LR + 缺失指示	0.0401	0.763	0.410	0.075	0.136	1472 / 37
RF + 缺失指示	0.0352	0.788	0.481	0.087	0.156	1296 / 33
RF 无指示	0.0331	0.763	0.476	0.083	0.150	1307 / 37

平衡权重 LR 的截距明显低于零，表明其预测分数相对于实际死亡率偏高。类别加权改变了模型输出的概率尺度，阈值调整和概率校准是不同的操作。

7 分组评价与特征选择敏感性

表 12: 冻结主模型的分组性能（全缺失组报告 95% CI）

测试子组	记录数	死亡	AUROC	AP
五项实验室均缺失	877	36	0.523 [0.427, 0.607]	0.043 [0.036, 0.056]
至少一项实验室有值	1775	120	0.769	0.275
原始月龄 0–216	2635	155	0.726	0.230

全缺失组只有 36 条死亡记录，分层 bootstrap 区间较宽，不能据点估计确认区分度高于随机。训练集内的前向选择保留全部 6 项特征，测试 AUROC 为 0.690，AP 为 0.182，与普通 LR 相同（按报告精度）。

8 主模型解释

在留出测试集上对冻结随机森林计算置换重要性。每个原始变量独立打乱十次，缺失状态随原值一同置换。以原 AP 减置换后平均 AP 为点估计，对同一批原始和置换分数作 1,000 次配对分层 bootstrap。区间反映给定模型及置换序列的测试抽样变异。

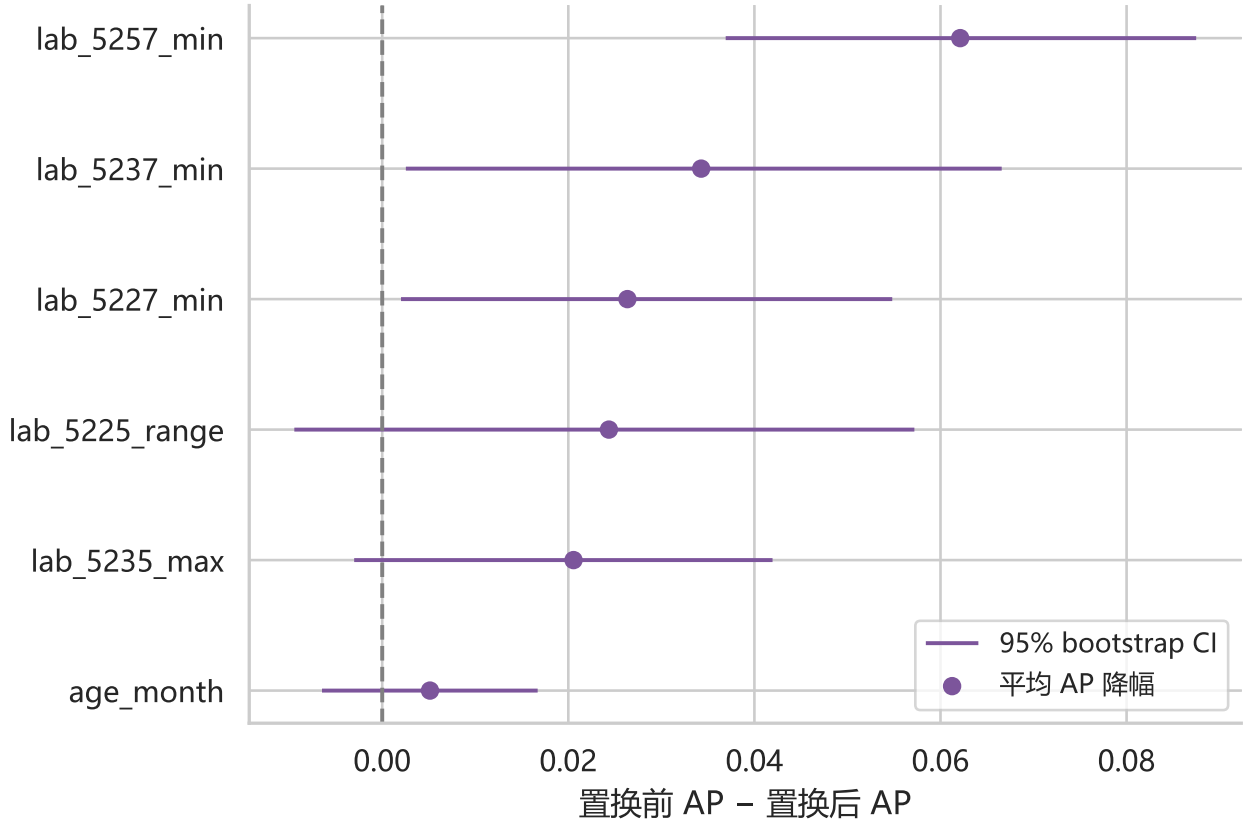


图 5: 随机森林的全局置换重要性。点表示 AP 降幅，横线为 95% CI。

随机森林 AP 降幅的首位变量为 lab_5257_min。平衡权重 LR 的平均绝对 SHAP 首位变量为 lab_5257_min。两者的首位变量一致。置换重要性衡量模型对输入的依赖，且同时包含原值与缺失状态的作用。SHAP 在平衡 LR 的 log-odds 尺度上分解单条预测。两者不能直接比较数值大小，也不能作因果解释。

表 13: 主模型全局重要性 [95% CI]

变量	AP 降幅
lab_5257_min	+0.0621 [+0.0369, +0.0875]
lab_5237_min	+0.0343 [+0.0025, +0.0666]
lab_5227_min	+0.0264 [+0.0020, +0.0548]
lab_5225_range	+0.0244 [-0.0094, +0.0572]
lab_5235_max	+0.0206 [-0.0030, +0.0419]
age_month	+0.0051 [-0.0065, +0.0167]

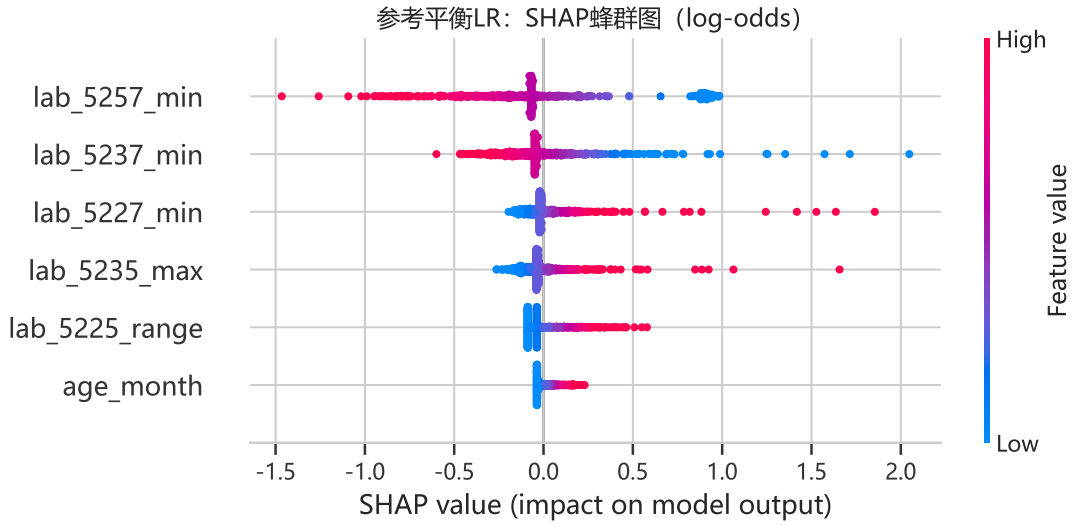


图 6: 课程参考：平衡权重 LR 的 SHAP 蜂群图。背景样本来自训练集。

9 讨论与结论

随机森林相较普通 LR 的排序能力有所提高，Brier 绝对值仅略有改善（表 9）。主模型在冻结阈值下有 1,296 条存活记录被误报、33 条死亡记录漏判。内部验证结果尚不足以支持临床应用。同参数无指示随机森林的 AUROC 为 0.713，普通 LR 为 0.690，带指示随机森林为 0.724。排序改善大部分在不加缺失指示时已出现，提示主要来自非线性模型。模型间比较仍包含算法差异，不能精确分解非线性的作用。逻辑回归加入缺失指示未显示实质增益。随机森林的同参数消融区间均跨零，缺失指示的额外贡献很小且不确定。平衡权重 LR 的概率尺度偏移，五项实验室均缺失组的区分度不确定。结果应结合概率校准、误报与漏判以及信息可得性解读。

1. 单中心历史教学数据，缺少外部和时间验证。
2. 缺少患者 ID，无法核验记录独立性或按患者划分。
3. 缺少时间字段，无法核验前 24 小时窗口与早期死亡排除。
4. 匿名实验室变量的定义、单位和上游筛选过程未知。
5. 缺失与结局相关，完整病例分析可能有选择偏倚。
6. 探索性回归依赖模型形式，分组界点没有临床解释。
7. Bootstrap 固定模型，按记录重采样，未涵盖训练或患者内相关的不确定性。
8. 未评价临床效用或前瞻性表现。

复现入口为 `analysis.py`，汇总表和图分别在 `tables/`、`figures/`。

数据 SHA256：

`77bebefce09b2127a79a09c4c0fbf8346a60ab3d870ad25f8dff3a2d6025444b`

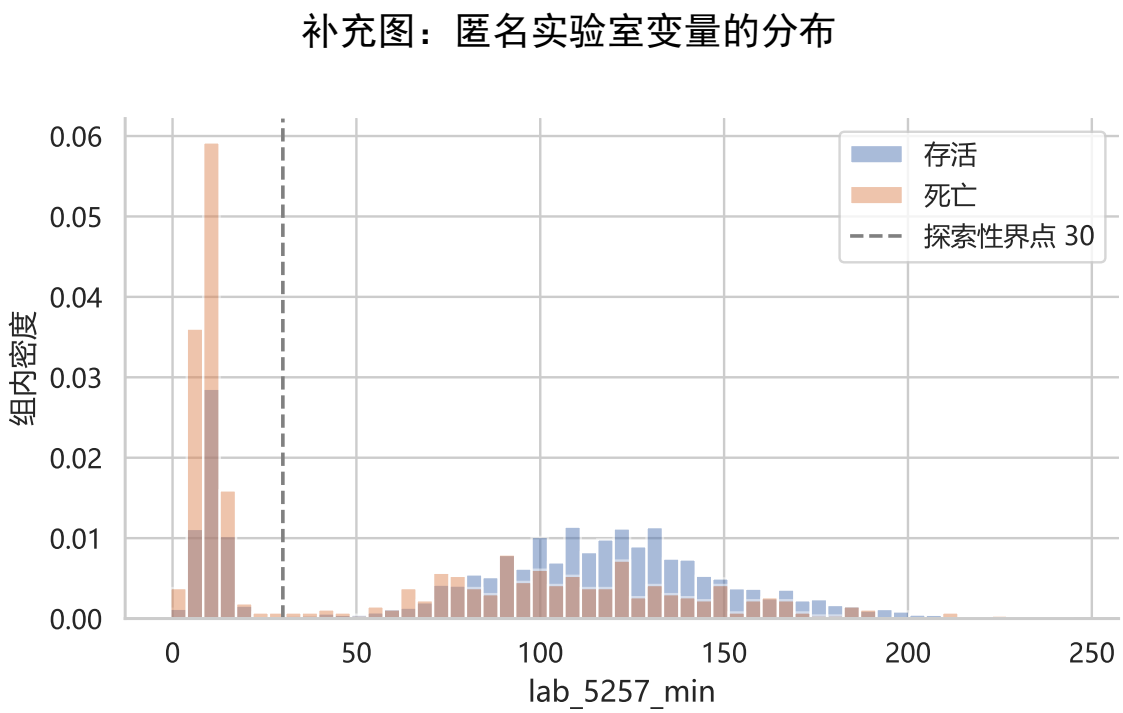


图 7: `lab_5257_min` 的非缺失值分布。两结局组分别归一为组内密度。

参考文献

[1] Zeng X, Yu G, Lu Y, et al. PIC, a paediatric-specific intensive care database. Scientific Data. 2020;7:14. https://doi.org/10.1038/s41597-020-0355-4.

[2] Hong S, Hou X, Jing J, Ge W, Zhang L. Predicting Risk of Mortality in Pediatric ICU Based on Ensemble Step-Wise Feature Selection. Health Data Science. 2021:9365125. https://doi.org/10.34133/2021/9365125.