临床医学公开数据库课程报告

基于 PIC 衍生教学数据的
儿童重症患者院内死亡风险预测

肖璇

2611210700@stu.pku.edu.cn

个人主页：https://xiaoxuan2004.github.io/

摘要

目的 评价儿童重症患者院内死亡预测，并衡量缺失指示的增量贡献。

方法 纳入 13,258 条记录、死亡 780 条（5.88%）。保留种子 42 的分层 80/20 主划分，训练集内选择模型和阈值；新增患者分组验证、重复嵌套交叉验证及等预算调参。

结果 冻结的带指示 RF 在原测试集上 AUROC 为 0.724 [0.681, 0.768]，AP 为 0.228 [0.171, 0.297]。相对无指示 RF，AUROC 差值为 +0.0114 [-0.0015, +0.0232]。患者分组验证中，RF 相对 LR 的三项性能差值区间均跨零。

结论 原划分下 RF 的排序较好、Brier 仅略有改善；该优势未在患者分组验证中得到明确确认。缺失指示的附加贡献较小且不稳定。结果限于内部探索性验证。

关键词：PIC；院内死亡；患者分组；随机森林；消融实验

核心发现 记录级表现不能替代新患者验证；较高的 AUROC 不等于可靠的概率或临床效用。

1 数据来源、队列与数据读取

PIC 是中国单中心儿科重症数据库 [1]。本分析读取课程提供的 `data.xlsx`。输入为月龄及五项匿名实验室特征，结局为 `HOSPITAL_EXPIRE_FLAG`。统计单位为记录。Hong 等 [2] 在入院后前 24 小时汇总时间变化特征，排除了这段时间内死亡的 191 例。其表 1 报告开发集 10,606 例和测试集 2,652 例，共 13,258 例。两组分别死亡 630 例和 150 例，合计 780 例。已核对作者仓库全部 13,258 行：教学 Excel 与仓库 tutorial/data.xlsx 的 SHA256 完全相同；六特征及标签与完整 CSV 按行对应，缺失位置一致，仅有浮点序列化舍入。官方种子 0 随机排列可复现开发/测试死亡数 630/150；本报告主划分为 624/156。完整 CSV 含 13,258 个住院 ID 和 12,690 个患者 ID。按现有行序对应元数据，原主划分共享 160 名患者，涉及 171 条测试住院记录。该映射以原行序保持为前提；相同保留字段的记录若曾内部交换，无法仅凭 Excel 识别。作者提取代码以 `ADMITTIME` 为原点，并非 ICU 入室时间；只检查时间差小于 24 小时，未检查非负下界。聚合文件没有原始事件时间及被排除记录，不能独立重算采集窗口或早期死亡排除。

表 1: 数据读取与分析人群

分析阶段	记录数	死亡数
原始及清理后	13,258	780
训练集	10,606	624
留出测试集	2,652	156
关联回归完整记录	8,539	587

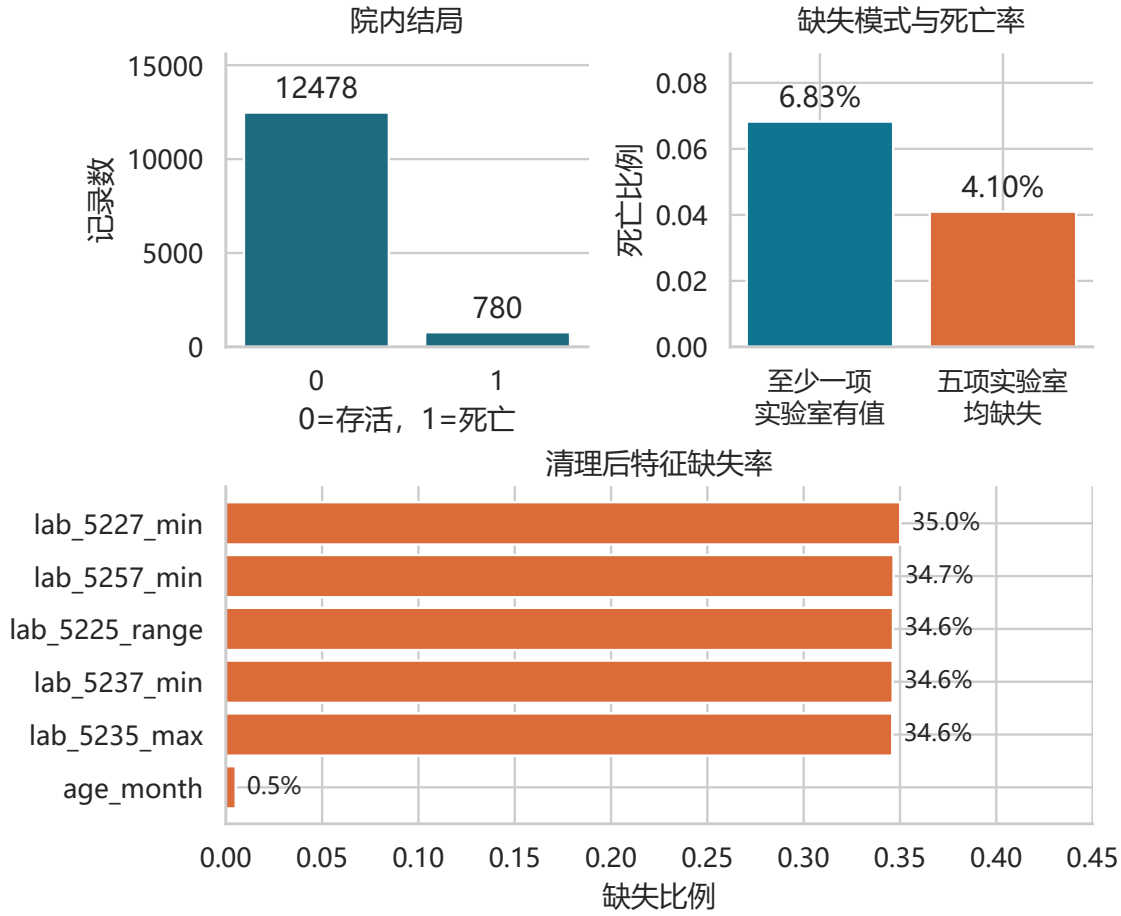


图 1: 全样本的结局、缺失模式及各特征缺失率，仅作描述。

2 预处理、缺失模式与描述性统计

将 68 条负月龄设为缺失，零月龄保留。原始月龄超过 216 个月的 2 条记录保留并做敏感性评价。保留 4,306 条重复特征及结局记录；特征相同不等于相同住院。五项实验室均缺失的记录有 4,587 条。训练折内拟合中位数插补，LR 另做标准化，均封装在 Pipeline 中 [3]。含指示模型在插补前记录缺失状态。结局比较、缺失分析及关联回归均为全样本探索描述，不用于预测特征筛选或阈值选择。连续变量使用非缺失观测和双侧 Mann–Whitney U 检验，按 BH 校正 [6]。SMD 为死亡组减存活组的标准化均值差。 可比性表描述已观测变量的不平衡程度；SMD 较小不能证明不存在选择偏倚，也不能消除同一患者跨集的问题。缺失比例在结局组间不同。缺失状态可能包含记录过程的信息，现有字段不足以识别缺失机制。

表 2: 按结局描述非缺失观测

变量	存活中位数 [IQR]	死亡中位数 [IQR]	SMD	BH q
age_month	9 [1, 42]	5 [0, 31]	-0.060	<0.001
lab_5237_min	7.37 [7.31, 7.42]	7.3 [7.16, 7.37]	-0.690	<0.001
lab_5227_min	1.8 [1.2, 2.7]	2 [1.2, 3.2]	0.241	<0.001
lab_5225_range	1.2 [0, 5.7]	5.2 [0.475, 11.1]	0.541	<0.001
lab_5235_max	39.3 [34, 46.1]	46.4 [37.1, 60.4]	0.528	<0.001
lab_5257_min	107 [55, 132]	15.2 [9.4, 103]	-0.677	<0.001

表 3: 按结局的观测数与缺失数

变量	存活观测	死亡观测	存活缺失	死亡缺失
age_month	12412	778	66	2
lab_5237_min	8076	592	4402	188
lab_5227_min	8026	590	4452	190
lab_5225_range	8074	592	4404	188
lab_5235_max	8079	592	4399	188
lab_5257_min	8072	590	4406	190

表 4: 原划分训练集与测试集可比性（全表仅描述）

变量	训练均值 ±SD	测试均值 ±SD	缺失率：训/测	SMD
age_month	29.97±43.85	30.87±45.04	0.5%/0.6%	0.020
lab_5237_min	7.35±0.12	7.35±0.11	35.0%/33.1%	0.040
lab_5227_min	2.23±1.80	2.30±1.91	35.4%/33.6%	0.038
lab_5225_range	3.91±5.53	3.58±5.21	35.0%/33.1%	-0.061
lab_5235_max	42.74±14.88	42.10±14.45	35.0%/33.1%	-0.043
lab_5257_min	91.31±55.26	92.45±55.20	35.0%/33.1%	0.020
死亡比例	5.88%	5.88%	0.0%/0.0%	-0.000

3 探索性统计关联与共线性

关联回归使用 statsmodels[5]。单因素使用各变量非缺失记录，多因素使用六特征完整记录，均为全样本探索。各自按对应样本 IQR 缩放，区间由 HC0 稳健标准误计算；未调整患者聚类或用于因果推断。两种模型的人群及 IQR 可能不同，OR 变化不能只归因于协变量调整。月龄的 Mann–Whitney 检验 BH $q < 0.001$，检验的是两结局组的秩分布差异。单因素和调整后的线性 OR 区间均含 1。表 6显示死亡率随月龄先降后升，单一线性项不能表达这种形状。敏感性模型保留其他五项变量，在完整记录上以 $(36, 120]$ 月为参照，用月龄组替代线性月龄。分组 OR 仍是探索性关联。`lab_5257_min` 呈双峰（图 3）。非缺失值的第 5、25 和 50 百分位为 7.7、17.6 和 105。低于 30 的记录占 25.72%，死亡率为 14.00%，其余记录为 4.32%。按 IQR 缩放的线性 OR 难以描述两个值簇之间的变化。30 是基于分布的探索性界点，无临床阈值含义。变量的临床定义和单位未知。

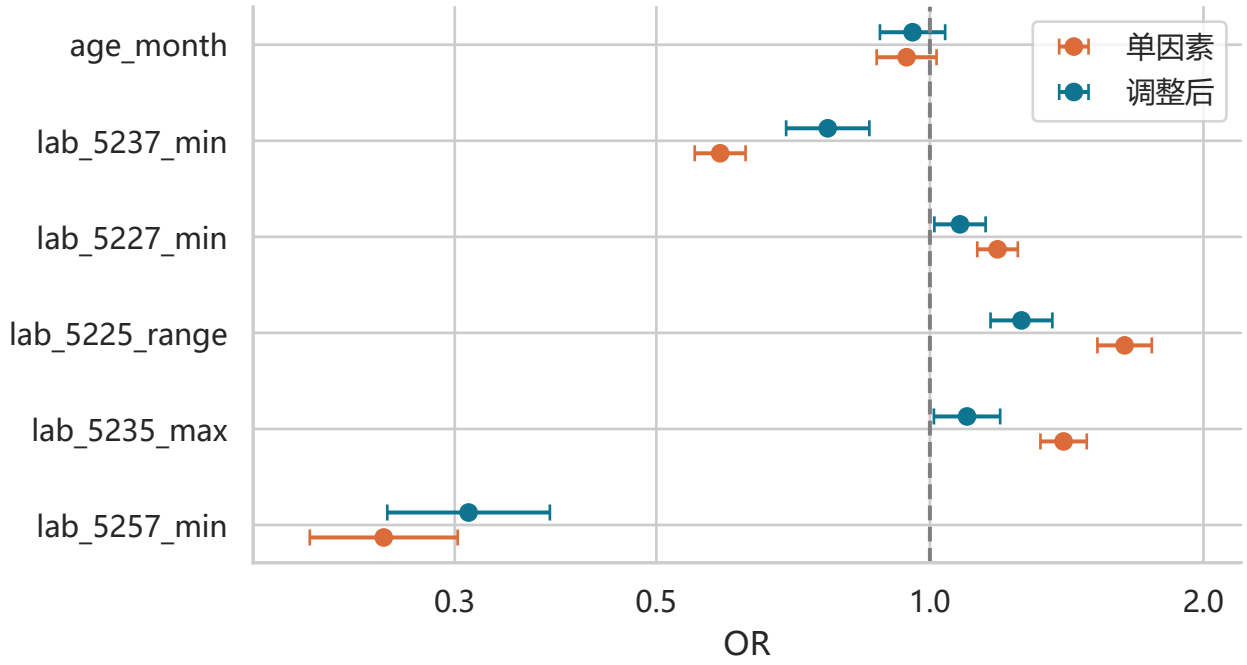


图 2: 单因素与调整后 OR 及 95% CI。横轴采用对数尺度。

表 5: 单因素与多因素 OR 对照（95% CI）

变量	IQR：单 / 多	单因素 OR	调整后 OR	VIF
age_month	41 / 36	0.943 [0.874, 1.017]	0.957 [0.881, 1.039]	1.04
lab_5237_min	0.109 / 0.108	0.588 [0.551, 0.627]	0.772 [0.695, 0.858]	2.77
lab_5227_min	1.5 / 1.5	1.187 [1.128, 1.250]	1.079 [1.011, 1.152]	1.21
lab_5225_range	6 / 6	1.638 [1.529, 1.755]	1.261 [1.166, 1.364]	1.32
lab_5235_max	12.7 / 12.8	1.403 [1.323, 1.488]	1.099 [1.010, 1.195]	2.25
lab_5257_min	113 / 113	0.251 [0.208, 0.302]	0.311 [0.253, 0.382]	1.08

表 6: 月龄组死亡率及分组敏感性回归

月龄	记录数	死亡	死亡率	调整 OR [95% CI]
不超过 1	3844	270	7.02%	1.522 [1.143, 2.026]
(1, 12]	3502	217	6.20%	1.432 [1.053, 1.947]
(12, 36]	2257	109	4.83%	1.413 [1.009, 1.979]
(36, 120]	2625	119	4.53%	参照
>120	962	63	6.55%	1.459 [0.959, 2.220]

表 7: 双峰变量按探索性界点分组

范围	记录数	死亡	死亡率
至少 30	6434	278	4.32%
低于 30	2228	312	14.00%

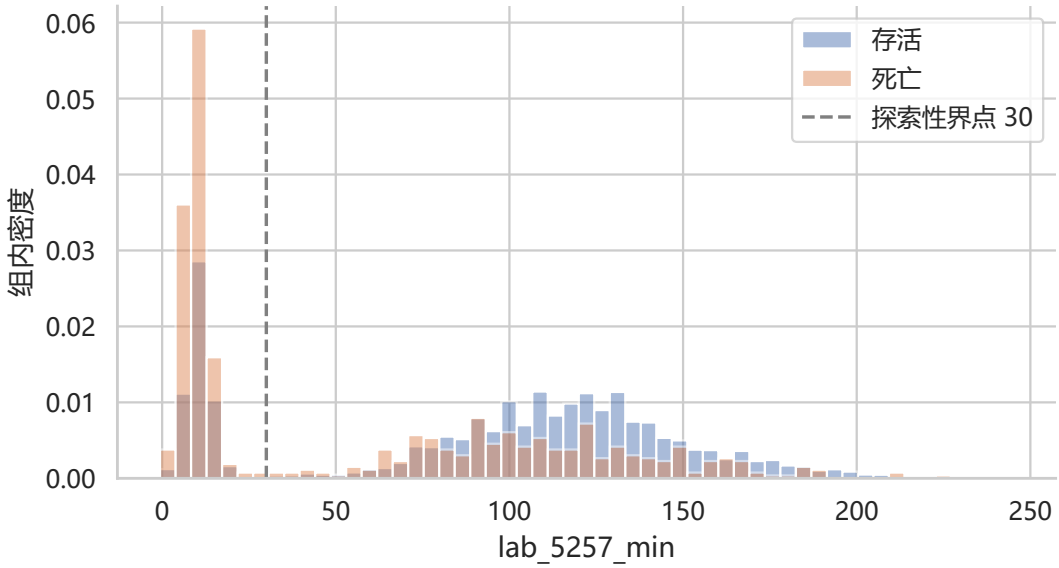


图 3: `lab_5257_min` 的双峰分布。两结局组分别归一为组内密度，变量单位未知。

4 预测模型建立与训练集选择

随机种子固定为 42，按标签分层作 80/20 划分。原候选模型使用相同的训练集五折分层 CV，按平均 AP 选参数及主模型。普通 LR 和平衡权重 LR 的 $C = 1$，缺失指示 LR 的候选 C 值为 0.1、1 和 10。主随机森林搜索深度 5 或不限、叶节点最少 5 或 20 条记录，树数固定为 200。保留原训练 CV 选出的带指示 RF 为冻结主模型。消融固定其参数，仅改变是否添加缺失指示。原搜索预算不等，补充分析另对各模型使用四组候选参数、相同五折 CV；它与同参数消融回答不同问题，不据测试结果替换主模型。代码已移除强制赢家断言。选定参数后，按训练集五折折外（OOF）预测，在灵敏度至少 0.80 的候选阈值中最大化特异度。阈值在测试前冻结。折间 SD 描述交叉验证的波动。 等预算

表 8: 训练集五折交叉验证

模型	AP 均值	AP 折间 SD	AUROC	Brier
无信息基线	0.059	0.000	0.500	0.055
普通 LR	0.191	0.030	0.717	0.052
平衡权重 LR	0.191	0.027	0.717	0.201
LR + 缺失指示	0.191	0.029	0.716	0.052
RF + 缺失指示	0.222	0.036	0.728	0.051
RF 无指示	0.219	0.037	0.726	0.051

下 CV AP 点估计最高的是 RF 无指示（0.225）。这不是独立检验，不能据此宣布其显著优于其他模型；该结果也不支持把缺失指示视为主要优势来源。

5 测试集性能与不确定性

在 2,652 条测试记录（死亡 156 条）上评价连续分数。AP 为按召回增量加权的平均精确率，Brier 为概率平方误差。固定模型与阈值后，按结局分层重采样 1,000 次，以百分位数计算 95% CI。全部

表 9: 等预算调参敏感性：每模型四候选 × 五折

模型	拟合次数	最佳 CV AP	最佳参数
普通 LR	20	0.191	C=0.01
平衡权重 LR	20	0.192	C=0.01
LR + 缺失指示	20	0.191	C=0.01
RF 无指示	20	0.225	深度 =5，叶 =5
RF + 缺失指示	20	0.222	深度 =None，叶 =5

模型共用重采样索引。差值点估计来自原测试集，区间来自逐次配对差值。全判存活的无信息基线准确率为 94.12%，死亡召回率为 0.0%，说明准确率不能单独反映少数结局识别。 表 11中，同参数消

表 10: 留出测试集性能 [95% CI]

模型	AUROC	AP	Brier
无信息基线	0.500 (—)	0.059 (—)	0.055 (—)
普通 LR	0.690 [0.642, 0.740]	0.182 [0.139, 0.246]	0.052 [0.050, 0.054]
平衡权重 LR	0.688 [0.639, 0.738]	0.181 [0.140, 0.247]	0.199 [0.194, 0.205]
LR + 缺失指示	0.691 [0.642, 0.741]	0.183 [0.140, 0.247]	0.052 [0.050, 0.054]
RF + 缺失指示	0.724 [0.681, 0.768]	0.228 [0.171, 0.297]	0.051 [0.049, 0.053]
RF 无指示	0.713 [0.669, 0.757]	0.220 [0.166, 0.291]	0.051 [0.049, 0.053]

表 11: 主模型减对照模型的测试性能差值 [95% CI]

对照模型	AUROC	AP	Brier
RF 无指示	+0.0114 [-0.0015, +0.0232]	+0.0078 [-0.0066, +0.0175]	-0.0002 [-0.0005, +0.0002]
普通 LR	+0.0347 [+0.0060, +0.0643]	+0.0452 [+0.0106, +0.0790]	-0.0013 [-0.0024, -0.0002]

融的三个区间均跨 0，缺失指示的附加贡献较小且不确定。普通 LR 与指示 LR 的测试 AP 分别为 0.182 与 0.183，未见实质增益。主模型相对普通 LR 的排序能力有所提高，Brier 绝对值仅略有改善。冻结 RF 的 CV AUROC 为 0.728，原测试 AUROC 为 0.724，两者点估计接近。调参 CV 有选择乐观性，且患者可能跨集，因此这种接近不能证明没有过拟合。

6 概率校准与分类阈值

测试集按预测概率分位数划分为最多八箱。另用二项 logistic 回归同时估计截距和斜率，自变量为预测概率的 log-odds，概率先裁到 [0.000001, 0.999999]。区间为模型标准误的 Wald 95% CI。理想截距为 0，斜率为 1。该回归只诊断校准，不修改预测。 平衡权重 LR 的截距明显低于零，表明其预测分数相对于实际死亡率偏高。类别加权改变了模型输出的概率尺度，阈值调整和概率校准是不同的操作。预测分数分布与冻结阈值见图 6。两结局组分别归一化，重叠部分显示单一阈值无法同时消除误报与漏判。网页滑块仅用于解释冻结模型，不据测试结果重新确定阈值。

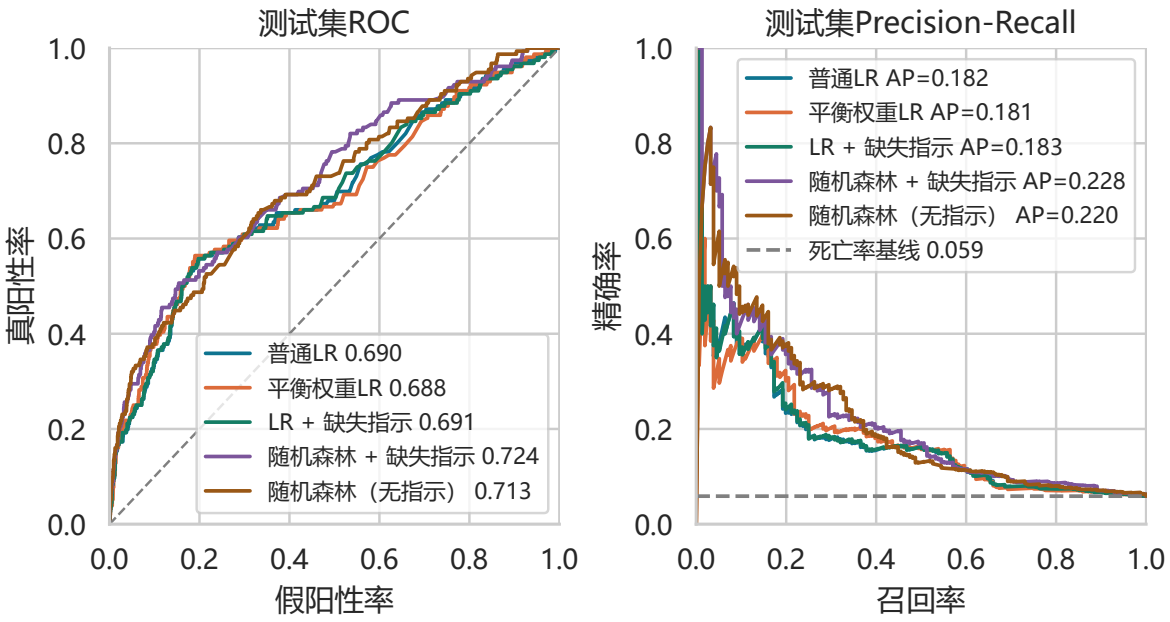


图 4: 留出测试集 ROC 与 PR 曲线。PR 虚线表示测试集死亡比例。

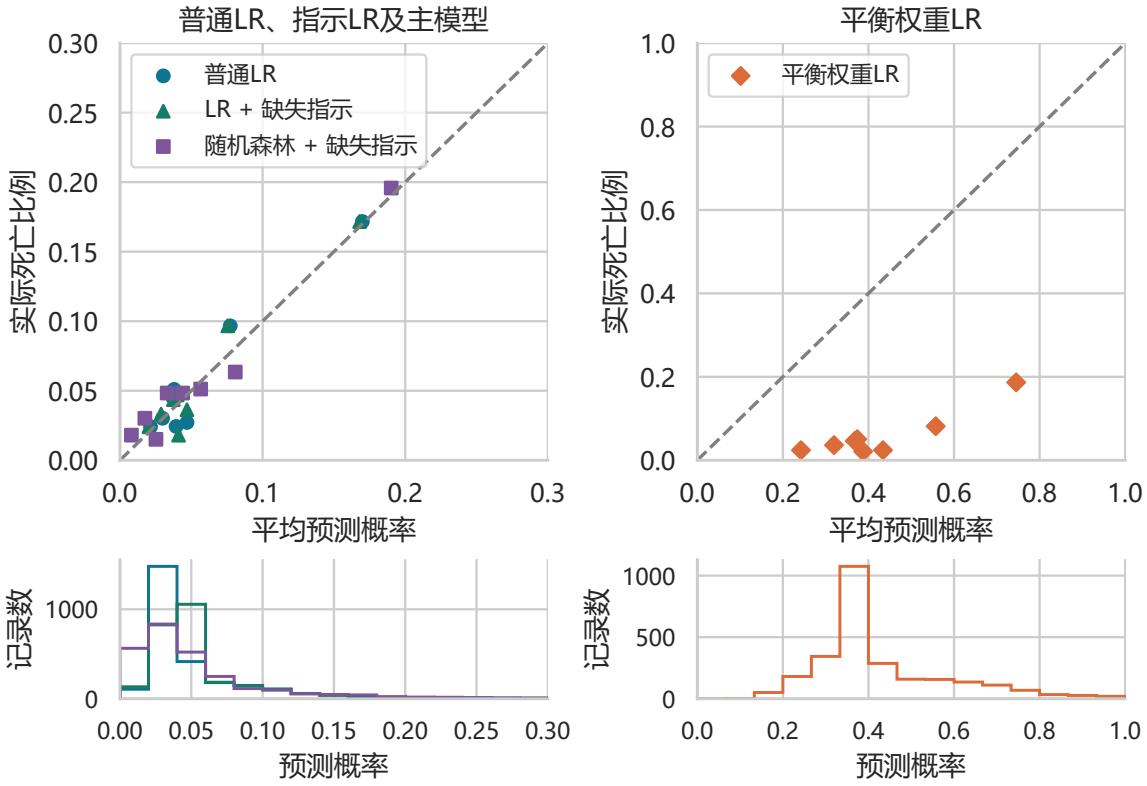


图 5: 分位箱校准散点与预测概率直方图。左：普通 LR、指示 LR 和冻结 RF，范围 0–0.3；右：平衡权重 LR，范围 0–1。虚线表示理想校准，各箱记录数保存于 calibration_bins.csv。

表 12: 测试集校准回归 [95% CI]

模型	校准截距	校准斜率
普通 LR	-0.004 [-0.519, 0.512]	0.988 [0.799, 1.177]
平衡权重 LR	-2.736 [-2.906, -2.566]	0.839 [0.676, 1.002]
LR + 缺失指示	0.005 [-0.515, 0.525]	0.990 [0.800, 1.181]
RF + 缺失指示	-0.132 [-0.581, 0.317]	0.931 [0.763, 1.099]

表 13: 训练 OOF 冻结阈值在测试集的表现

模型	阈值	灵敏度	特异度	PPV	F1	FP	FN
普通 LR	0.0382	0.699	0.494	0.080	0.143	1262	47
平衡权重 LR	0.3765	0.673	0.498	0.077	0.139	1253	51
LR + 缺失指示	0.0401	0.763	0.410	0.075	0.136	1472	37
RF + 缺失指示	0.0352	0.788	0.481	0.087	0.156	1296	33
RF 无指示	0.0331	0.763	0.476	0.083	0.150	1307	37

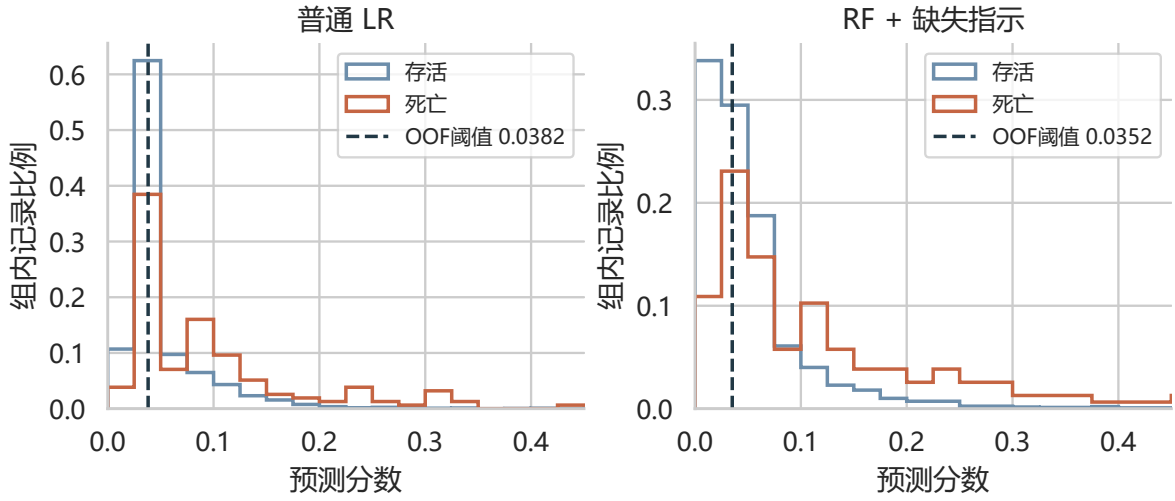


图 6: 普通 LR 与冻结 RF 的预测分数分布及训练 OOF 阈值。按结局分别归一；横轴放大低分区间，完整分箱保存于 CSV。

7 验证、缺失处理与特征选择敏感性

表 14: 官方行划分与患者分组验证人群

划分	训练 n/死亡	测试 n/死亡	共享患者
官方 seed 0	10606/630	2652/150	174
患者分组	10610/618	2648/162	0

补充验证先核对完整 CSV 与教学表按行一致，再使用患者 ID。患者留出采用五折 StratifiedGroupKFold 的预先固定第一折，组间患者不重叠；分组训练集内部也按患者作五折调参和 OOF 阈值选择。官方划分仅复现原行序和划分，仍只使用六变量，不是复现论文完整模型。每种划分独立调

参，LR 与带指示 RF 均用四组候选；无指示 RF 为同参数消融。 患者分组验证中，RF 相对普通

表 15: 补充留出验证：性能及患者聚类 bootstrap 95% CI

划分	模型	AUROC	AP	Brier
官方	普通 LR	0.731 [0.682, 0.773]	0.172 [0.133, 0.229]	0.051 [0.044, 0.058]
官方	RF 无指示	0.753 [0.710, 0.792]	0.207 [0.158, 0.271]	0.049 [0.043, 0.056]
官方	RF + 缺失指示	0.750 [0.709, 0.789]	0.198 [0.154, 0.268]	0.049 [0.043, 0.056]
患者分组	普通 LR	0.715 [0.677, 0.757]	0.181 [0.137, 0.246]	0.055 [0.047, 0.062]
患者分组	RF 无指示	0.735 [0.694, 0.774]	0.196 [0.149, 0.258]	0.054 [0.047, 0.061]
患者分组	RF + 缺失指示	0.733 [0.691, 0.774]	0.197 [0.150, 0.260]	0.054 [0.047, 0.061]

表 16: 患者分组验证：带指示 RF 减对照的差值 [95% CI]

对照	AUROC	AP	Brier
普通 LR	+0.0171 [-0.0017, +0.0348]	+0.0162 [-0.0075, +0.0433]	-0.0008 [-0.0019, +0.0001]
RF 无指示	-0.0024 [-0.0086, +0.0048]	+0.0016 [-0.0071, +0.0094]	-0.0001 [-0.0004, +0.0002]

LR 的 AUROC、AP、Brier 差值区间均跨零，未确认原主划分上的优势；这也不证明两模型等效。同参数消融的三个区间也均跨零。补充区间以测试患者为单位重采样，患者内记录一起进入，不按记录结局分层，因此死亡比例允许变化；全部模型共用索引。它们仍固定训练完成的模型，不覆盖重新训练的不确定性。对原主划分改用患者聚类重采样时，同参数消融的 AUROC 差值区间为 +0.0114 [+0.0004, +0.0239]，略高于零；AP 和 Brier 区间仍跨零。这说明区间依赖重采样定义，不能把记录级与患者级区间混为一谈，也不足以确认稳定的缺失指示增益。仅在原训练集作外层五折、重复 2

表 17: 原训练集重复嵌套 CV：外层折均值 ±SD

模型	AUROC	AP	Brier
普通 LR	0.717±0.038	0.189±0.025	0.052±0.001
RF 无指示	0.734±0.033	0.220±0.036	0.051±0.001
RF + 缺失指示	0.736±0.032	0.218±0.035	0.051±0.001

次、内层三折的嵌套 CV，内层重新调参。折间 SD 是描述性波动，不是置信区间，外层折之间也并非独立样本。该实验仍按记录划分，患者分组验证是另外一项实验；两者均不能代替外部验证。 均

表 18: 均值/中位数插补敏感性：其他模型参数保持一致

模型	填补	AUROC	AP	召回率	阈值
普通 LR	中位数	0.690	0.182	0.699	0.0382
普通 LR	均值	0.694	0.183	0.808	0.0459
RF + 缺失指示	中位数	0.724	0.228	0.788	0.0352
RF + 缺失指示	均值	0.721	0.225	0.821	0.0340

值插补与中位数插补仅改变填补规则，其他参数不变。每个模型均独立按相同训练 OOF 规则确定阈

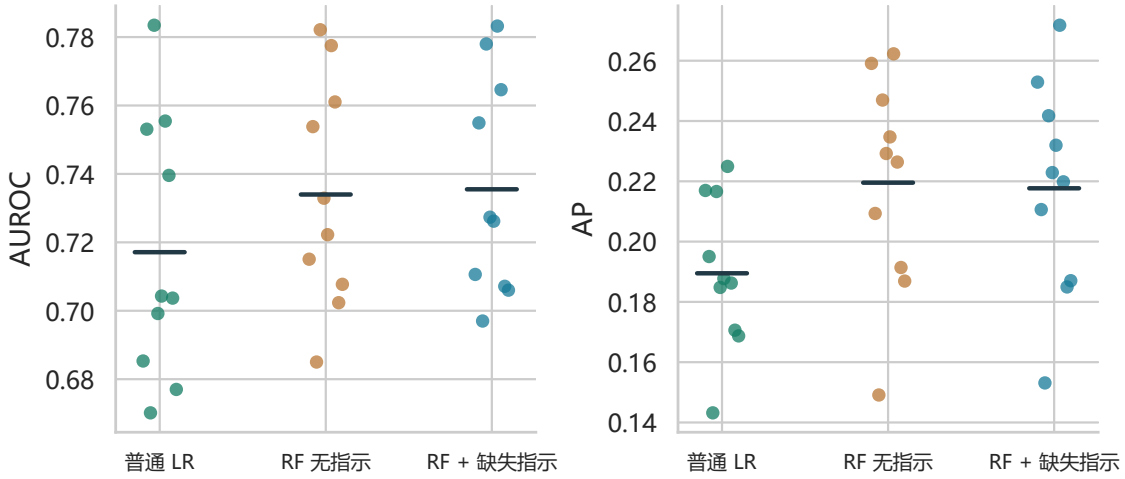


图 7: 原训练集重复嵌套 CV。点为外层验证折表现，横线为均值；折间波动不是置信区间。

值，所以召回率差异同时反映概率尺度和工作点变化；点估计差异不构成显著优越的证据。全缺失组

表 19: 冻结主模型的分组性能（全缺失组报告 95% CI）

测试子组	记录数	死亡	AUROC	AP
五项实验室均缺失	877	36	0.523 [0.427, 0.607]	0.043 [0.036, 0.056]
至少一项实验室有值	1775	120	0.769	0.275
原始月龄 0–216	2635	155	0.726	0.230

只有 36 条死亡记录，分层 bootstrap 区间较宽，不能据点估计确认区分度高于随机。训练集内的前向选择保留全部 6 项特征，测试 AUROC 为 0.690，AP 为 0.182，与普通 LR 相同（按报告精度）。

8 主模型解释

在留出测试集上对冻结随机森林计算置换重要性。每个原始变量独立打乱十次，缺失状态随原值一同置换。以原 AP 减置换后平均 AP 为点估计，对同一批原始和置换分数作 1,000 次配对分层 bootstrap。区间反映给定模型及置换序列的测试抽样变异。随机森林 AP 降幅的首位变量为 lab_5257_min。平衡权重 LR 的平均绝对 SHAP 首位变量为 lab_5257_min。两者的首位变量一致。置换重要性衡量模型对输入的依赖，且同时包含原值与缺失状态的作用。SHAP[4] 在平衡 LR 的 log-odds 尺度上分解单条预测；正值表示把模型输出推向更高风险，不能解释为相同数值的概率增量。两种重要性不能直接比较数值大小，也不能作因果解释。全部置换重要性数值见公开汇总表 `RF_permutation_importance.csv`。

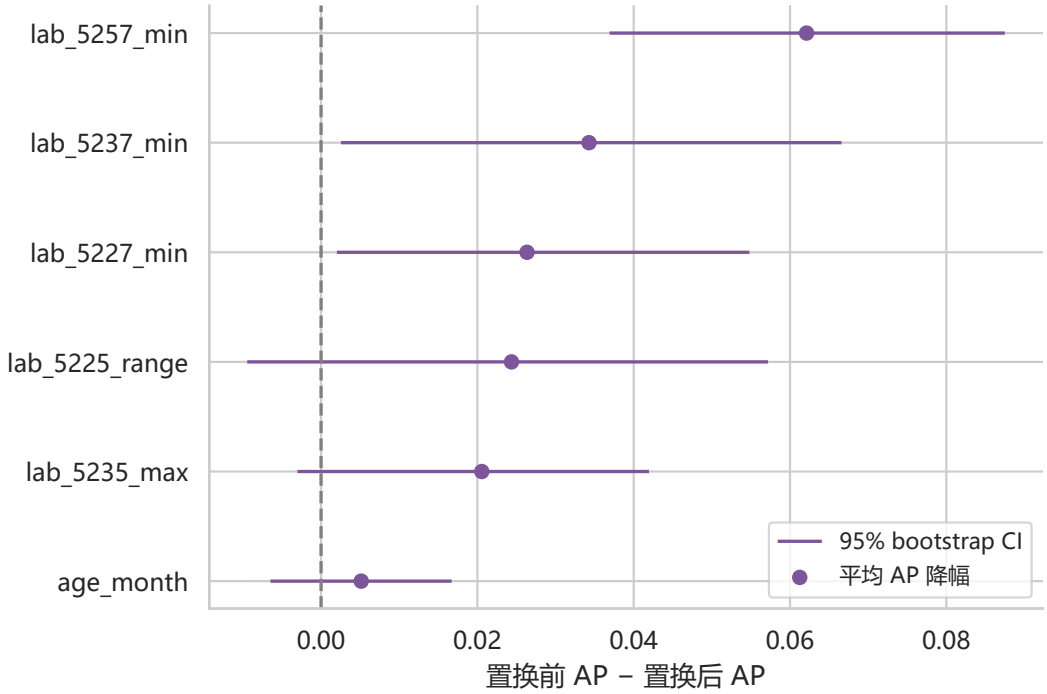


图 8: 随机森林的全局置换重要性。点表示 AP 降幅，横线为 95% CI。

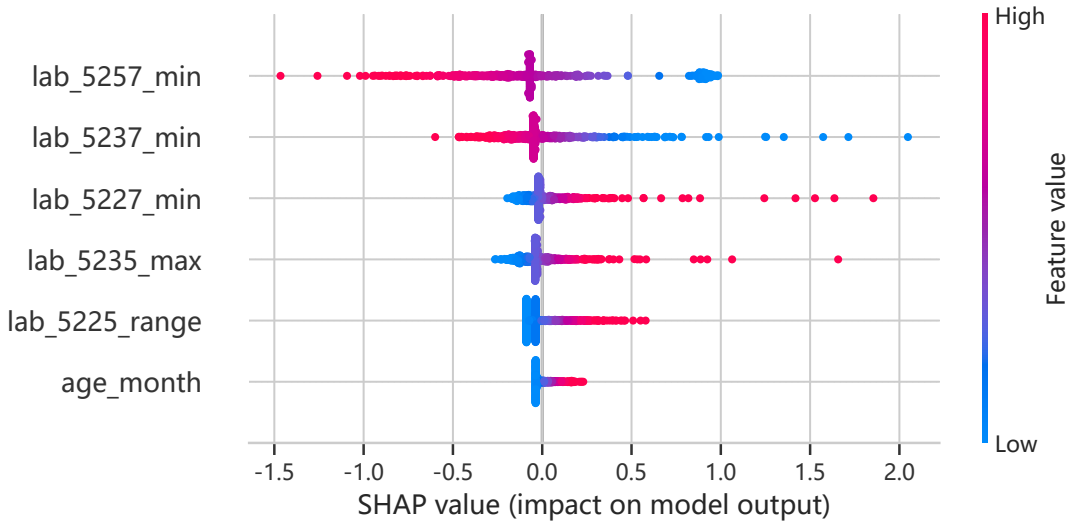


图 9: 课程参考：平衡权重 LR 的 SHAP 蜂群图。背景来自训练集，正值把输出推向更高风险，横轴为 log-odds。

9 讨论与结论

随机森林相较普通 LR 的排序能力有所提高，Brier 绝对值仅略有改善（表 11）。主模型在冻结阈值下有 1,296 条存活记录被误报、33 条死亡记录漏判。内部验证结果尚不足以支持临床应用。同参数无指示随机森林的 AUROC 为 0.713，普通 LR 为 0.690，带指示随机森林为 0.724。排序改善大部分在不加缺失指示时已出现，提示主要来自非线性模型。模型间比较仍包含算法差异，不能精确分解非线性的作用。逻辑回归加入缺失指示未显示实质增益。随机森林的同参数消融区间均跨零，缺失指示的额外贡献很小且不确定。患者分组验证未确认 RF 相对 LR 的优势，等预算搜索也没有显示缺失指示模型始终最优。因此，较好的原划分点估计不宜提升为稳定泛化优势。平衡权重 LR 的概率尺度偏移，全缺失组的区分度不确定；结果应结合概率校准及误报、漏判解读。按照 TRIPOD+AI[7]

的透明报告原则，本报告区分冻结主分析与事后补充验证，明确统计单位、上游特征来源和未完成的外部验证，不把解释图当作临床机制证据。

1. 单中心历史教学数据，仍缺少外部和可信的时间验证；重复 CV 不能替代这两种验证。
2. 原主划分共享 160 名患者；分组补充验证消除了已映射 ID 的重叠，但元数据映射仍以原行序保持为前提。
3. 缺少原始事件时间和被排除记录，无法核验严格的前 24 小时窗口与早期死亡排除。
4. 匿名实验室变量的定义、单位和上游筛选过程未知。
5. 全样本描述和关联回归是探索性的，完整病例分析可能有选择偏倚，HC0 标准误未处理患者聚类。
6. 探索性回归依赖模型形式，分组界点没有临床解释。
7. 记录级及患者聚类 bootstrap 均固定模型，未涵盖重新训练、调参和上游选特征的不确定性；新增补充实验不是新获得的外部测试集。
8. 六变量不足以实现完整 PRISM-III 基线，故未编造该评分；尚未评价临床效用或前瞻性表现。

A 可复现模型与课堂展示

普通 LR 的预测满足 $p = 1/(1+\exp(-\eta))$，其中 $\eta = b + \sum_j \beta_j z_j$，$z_j = (x_j^* - \mu_j)/s_j$，$x_j^*$ 先用训练中位数填补。该公式对应原冻结普通 LR，不是敏感性分析中的重新调参模型。截距 $b = -3.008661$。全部常数由已拟合 Pipeline 导出，并已核对公式概率与 Pipeline 输出一致。标准化 SD 使用总体标准差（ddof=0）。

表 20: 普通 LR 公式与训练预处理常数

变量	标准化系数	填补中位数	训练均值	训练 SD
age_month	0.038558	9	29.866	43.7659
lab_5237_min	-0.213379	7.367	7.35325	0.0950208
lab_5227_min	0.085372	1.8	2.08019	1.46368
lab_5225_range	0.192890	1.6	3.10025	4.58766
lab_5235_max	0.084315	39.7	41.6767	12.0812
lab_5257_min	-0.452013	104	95.7606	44.9441

分布图、箱线图、相关热图和高/低分 SHAP 瀑布图可在项目展示页的数据探索和模型解释折叠区查看。瀑布图仅演示平衡 LR 的 log-odds 分解，其未校准分数不能直接解释为实际死亡概率。

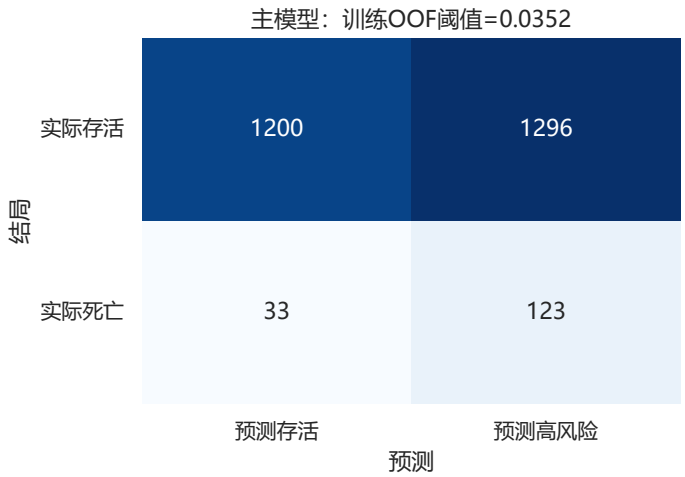


图 10: 冻结 RF 在原测试集的混淆矩阵，采用训练 OOF 阈值。

参考文献

[1] Zeng X, Yu G, Lu Y, et al. PIC, a paediatric-specific intensive care database. Scientific Data. 2020;7:14. https://doi.org/10.1038/s41597-020-0355-4.

[2] Hong S, Hou X, Jing J, Ge W, Zhang L. Predicting Risk of Mortality in Pediatric ICU Based on Ensemble Step-Wise Feature Selection. Health Data Science. 2021:9365125. https://doi.org/10.34133/2021/9365125.

[3] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python. J Mach Learn Res. 2011;12:2825–2830.

[4] Lundberg SM, Lee SI. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems. 2017;30.

[5] Seabold S, Perktold J. Statsmodels: Econometric and Statistical Modeling with Python. Proceedings of the 9th Python in Science Conference. 2010. https://doi.org/10.25080/Majora-92bf1922-011.

[6] Benjamini Y, Hochberg Y. Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. J R Stat Soc Series B. 1995;57(1):289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x.

[7] Collins GS, Moons KGM, Dhiman P, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ. 2024;385:e078378. https://doi.org/10.1136/bmj-2023-078378.